

Relatório_Card_03_Explicabiliadde_de_Modelos

 Navegação >


Central → Fastcamp LLM

Descrição da atividade

Relatório de entrega de card do card 3:

Word Embeddings

Para processar dados textuais, computadores precisam que eles sejam representados e estruturados de forma numérica, pois são incapazes de os interpretar semanticamente. Para isso ,utiliza-se os word embeddings; modelos de NLP que representam palavras como vetores numéricos, para capturar suas relações semânticas e contextuais em uma frase ou texto. Diferentemente de one-hot encoding que representa cada palavra em uma posição diferente do vetor, os word embeddings representam as palavras com vetores multi-dimensionais não binários, que posicionam palavras com significados semânticos semelhantes próximas entre si no espaço vetorial euclidiano, criando clusters de similaridade .



A técnica de word embedding é utilizada em várias tarefas de NLP:

- **Classificação de texto:** Detecção de spam, categorização de tópicos, etc;
- **NER (Named Entity Recognition):** Identificação dos nomes de entidades como pessoas, locais, organizações, países, entre outros;
- **Similaridade de palavras:** Identificação da relação semântica entre palavras, comparação de similaridade contextual;
- **Perguntas e respostas:** Resposta de perguntas a respeito de documentos, artigos, e outros tipos de texto em geral, com a utilização de comparação semântica para construir a resposta.

Modelos de embedding são treinados em grandes corpus de texto como enciclopédias, livros, ou toda a internet, no caso de modelos massivos. O treinamento é feito de forma supervisionada: janelas deslizantes identificam a palavra alvo e palavras de contexto, e tenta aprender a relação entre elas. Em seguida o modelo é treinado para inferir a palavra-alvo com base no seu contexto , e ajustar seus pesos para minimiar erros de predição. O treinamento de modelos de embedding se divide em duas grandes abordagens fundamentais:

Frequency-based: Modelos de embedding baseados frequência, criam representações que derivam da frequência das palavras em um corpus textual, com a premissa de que a importancia de uma palavra pode ser inferida com base na frequência em que ela aparece no texto. Um exemplo dde modelo de embedding baseado em frequência é o TF-IDF, que categoriza palavras com base na frequência em que aparecem em um texto(IF), e na sua ocorrência ao longo de todo o corpus. Palavras com uma alta frequência em um texto mas baixa no restante do corpus tem IF-IDF alto, e palavras cuja ocorrência é comum em todo o corpus tem IF-IDF baixo. No entanto, modelos de embedding bom base em frequência não capturam a relação posicional das palavras, e portanto, não capturam a relação semântica entre elas.

Prediction-Based embeddings: Embeddings baseados em predição são criados por modelos treinados para prever palavras com base no contexto em volta, capturando a relação semântica e informação contextual das palavras, podendo diferenciar sinônimos e similaridade contextual.

Explicabilidade de modelos

A adoção de arquiteturas de Deep Learning e Transformers em NLP melhorou substancialmente a precisão semântica, mas introduziu o desafio da opacidade das representações em alta dimensão(caixa preta). Compreender as decisões desses modelos é fundamental para auditar resultados e depurar comportamentos.

No txtai, a explicabilidade é usada de duas formas:

- **Busca Semântica:** O txtai implementa o método explain(), que realiza a busca semântica e calcula a relevância de cada token do texto para o score de similaridade final, expondo os pesos individuais de cada palavra para destacar visualmente os termos mais importantes.
- **SHAP:** A biblioteca SHAP quantifica a contribuição de cada palavra para a predição final do modelo, gerando valores positivos que impulsionam uma classe, ou negativos que a afastam, e que podem ser plotados diretamente no texto e em um gráfico de proporcionalidade.

Conclusões

A transição das representações baseadas em frequência para embeddings baseados em predição viabilizou a captura do significado semântico e do contexto das palavras, mas impôs o desafio da interpretação dos modelos de alta dimensão. O uso de ferramentas de explicabilidade, como txtai e shap, resolve esse problema ao fornecer transparência sobre o espaço latente. Esse controle não só viabiliza a auditoria de predições e a detecção de vieses nos dados de treinamento, como também estabelece um método robusto para a depuração de modelos em treinamento.

Referências

Nota/task do card:

Prática_Explicabilidade_de_modelosDue: May 2 (overdue)Scheduled: Apr 25 (past)

 O que são Word Embeddings? | Processamento de Linguagem Natural | Leonardo Ribeiro: <https://www.youtube.com/watch?v=9FmxpjwRQ0Q> Notebook Exemplo: [txtai/examples/32_Model_explainability.ipynb at master · neuml/txtai](#)

 Navegação >

Central → Fastcamp LLM