

A survey of Large Language Models

O artigo introduz a modelagem de linguagem como solução para a incapacidade das máquinas de se expressar através da linguagem natural, como fazem os seres humanos. O desenvolvimento das pesquisas em modelagem de linguagem é apresentado em quatro estágios:

- **Modelos de Linguagem Natural:** Baseados em métodos de aprendizado estatístico, estes modelos funcionam prevendo a probabilidade da próxima palavra com base no contexto mais recente, são chamados de n-gram quando tem um contexto de comprimento fixo n. Os n-gram foram utilizados em tarefas de processamento de linguagem natural e aquisição de informações, mas sua performance é limitada com o crescimento da janela de contexto.
- **Modelos de Redes Neurais:** Calcula a probabilidade da sequência de palavras utilizando redes perceptron multi-camada e redes neurais recorrentes. Foram muito importantes para o desenvolvimento da modelagem de linguagem ao introduzir as representações vetoriais contínuas das palavras, utilizando word2vec.
- **Modelos de linguagem pré treinados:** Foram propostos para capturar representações semânticas contextuais, treinando modelos altamente paralelizáveis baseados na arquitetura transformer, que empregam o uso de mecanismos de auto-atenção. Os modelos são pré treinados em corpos de larga escala, geralmente na ordem de petabytes de informação textual. A performance do processamento natural de linguagem foi fortemente impactada por esta abordagem, devido às representações contextualizadas e atributos semânticos aprendidos pelo modelo. Para aplicações específicas, os modelos pré treinados precisam passar por uma adaptação chamada de fine-tuning, onde o modelo é treinado com dados específicos da tarefa que irá realizar.
 - **Grandes modelos de linguagem:** Seu funcionamento não é muito diferente dos modelos pré treinados, se diferenciando pela escala. O escalamento de modelos pré treinados com datasets cada vez maiores fez com que surgissem habilidades emergentes não previstas, durante a execução de tarefas mais complexas. Estas habilidades são de suma importância, pois ao longo do tempo, os modelos de linguagem deixaram de apenas gerar textos e conversas e passaram a focar na resolução de tarefas complexas.

Embora mais eficientes e inteligentes, os grandes modelos de linguagem trazem seus próprios desafios. Dado o volume de dados e recursos computacionais necessários para o treinamento de LLMs, o treinamento destes modelos é restrito às grandes corporações, obscurecendo o desenvolvimento da tecnologia para os demais pesquisadores. Assim, não é possível, no momento, identificar as causas por trás das complexas habilidades e vieses que emergem durante o treinamento.

Escalonamento de modelos LLM

LLMs excedem os menores modelos transformer pré treinados em tamanho (quantidade de parâmetros), volume de dados de treinamento, e custo computacional. Tal dimensionamento se mostrou crucial para aumentar e muitas ordens de magnitude as habilidades de solução de tarefas complexas. Por este motivo, foram criadas as leis de dimensionamento para caracterizar a escala dos modelos transformer.:

- **Leis de potência:** Estudos da OpenAI indicaram que a performance do modelo aumenta conforme o seu tamanho, a quantidade de dados e tempo de treinamento, com base em parâmetros nomeados de *irreducible loss* e *reducible loss*.
- **Lei de escalonamento Chinchilla:** O estudo Chinchilla, conduzido pelo Google Deep Mind refinou a estratégia de escalonamento de modo que os modelos devem ser dimensionados para que o número total de tokens seja proporcional ao número de parâmetros.

O escalonamento dos modelos LLM, no entanto, tem suas limitações. A quantidade de dados necessária para treinar modelos cada vez maiores muito em breve se tornará um gargalo e além disso, também não é prático testar cada abordagem de treinamento disponível dado o tempo necessário para treinar um modelo.


Habilidades emergentes

Habilidades emergentes são caracterizadas como habilidades que não estão presentes em modelos menores, mas surgem em modelos maiores, e estão relacionadas à resolução de tarefas complexas específicas. Algumas habilidades emergentes são:

- **In-Context Learning:** Capacidade de aprender novas tarefas a partir de exemplos demonstrados no próprio prompt, sem a necessidade de fine-tuning. Esta habilidade foi demonstrada com o GPT-3.
- **Instruction Following:** É a habilidade de realizar tarefas a partir de instruções em linguagem natural, que nunca foram vistas durante o treinamento.
- **Chain-of-Thought Reasoning:** Capacidade de dividir tarefas complexas em subtarefas menores, utilizando raciocínio intermediário. É desencadeada pelo uso de prompts específicos sugerindo a segmentação da tarefa proposta.

As leis de escalonamento podem prever a performance dos modelos com base na *language modeling loss*, que descreve os ganhos de performance em relação a potenciais perdas. As habilidades emergentes, no entanto, não podem ser previstas, mas trazem ganhos inestimáveis uma vez que surgem durante o treinamento.

Aplicações de LLMs



O artigo explora o impacto que as LLMs causaram no desenvolvimento de algoritmos de inteligência artificial, e revisa os avanços em diferentes áreas de pesquisa e suas aplicações:

- LLM pra tarefas clássicas de NLP:** Tarefas específicas de processamento de linguagem natural antes eram executadas por modelos pré treinados específicos - tarefas a nível de palavra e sentença(word clustering, classificação de sentimento etc), classificação de sentenças, extração de informação e geração de texto - agora foram unificadas sob um único framework pelos LLM, que podem ser ajustados para executá-las com performance competitiva.
- LLM para aquisição de informação:** As LLMs revolucionaram a busca de informação combinando métodos tradicionais com síntese em linguagem natural, e ao integrar-se com motores de busca como google e bing. Ferramentas como WebGPT tem acesso à internet para executar tarefas de busca.
- LLM para sistemas de recomendação:** As LLMs podem ser adaptadas para capturar as preferências do usuário e prover os recursos adequados, gerando explicações contextualizadas dos itens e os otimizando por ranking de acordo com o contexto, superando as abordagens tradicionais baseadas em embeddings.
- Agentes baseados em LLM:** Agentes autônomos são entidades que podem perceber seu ambiente, fazer decisões e realizar ações para alcançar um objetivo específico. LLMs, por sua capacidade de resolver problemas complexos, são utilizados como o componente computacional central na construção de modelos, através de ciclos iterativos de planejamento, execução, reflexão e refinamento, e tem sua capacidade aumentada pelo uso de ferramentas através de APIs externas.
- Sistemas multi-agente:** Sistemas multi-agente empregam múltiplas LLMs na solução de uma tarefa para alcançar a inteligência coletiva, com os agentes podendo ser instanciados do mesmo modelo, ou de modelos diferentes, cada um com funções e tarefas distintas. Os sistemas multi-agente podem ser colaborativos, onde os agentes compartilham informações e se auxiliam no desenvolvimento da solução através de protocolos de comunicação de diálogo livre, ou competitivos, onde os agentes debatem entre si para lapidar a solução ideal.

LLMs em domínios específicos

O artigo apresenta a utilização de LLMs em várias áreas do conhecimento distintas, como:

- Saúde:** Estudos já aplicaram LLMs na medicina, e foi constatado que eles podem solucionar diferentes tarefas médicas, como extração de informações biológicas, consulta de conselhos médicos, análise de saúde mental, entre outros. Modelos desenvolvidos para a área da saúde, como Med-PaLM, demonstraram um nível de performance comparável ao de médicos especialistas.
- Educação:** LLMs podem alcançar uma alta performance em testes padronizados de múltipla escolha e também dissertativos, além de gerar respostas sólidas e consistentes em múltiplos domínios do conhecimento, podendo ser uma ferramenta poderosa para o aprendizado.

- **Direito:** Na área do direito, LLMs podem realizar diversas tarefas legais, como análise de documento, previsão de julgamento, e escrita de documentos legais, além de exibir uma grande capacidade para interpretar textos legislativos, podendo ser empregados como assistentes legais.
- **Finanças:** LLMs podem ser empregadas em diversas tarefas na área financeira como detecção de reivindicações, análise financeira e raciocínio financeiro. No entanto, os modelos ainda não performam tão bem em tarefas com uma quantidade muito grande de parâmetros.
- **Pesquisa científica:** LLMs demonstraram uma grande habilidade em conduzir tarefas de alta intensidade intelectual, especialmente modelos que foram treinados em grandes corpus de texto científico. LLMs tem potencial para auxiliar em todas as etapas da pesquisa científica: revisão de literatura, geração de hipóteses científicas e análise, incluindo a exploração e visualização de dados.